โครงงาน MACHINE LEARNING

Student Dropout Prediction

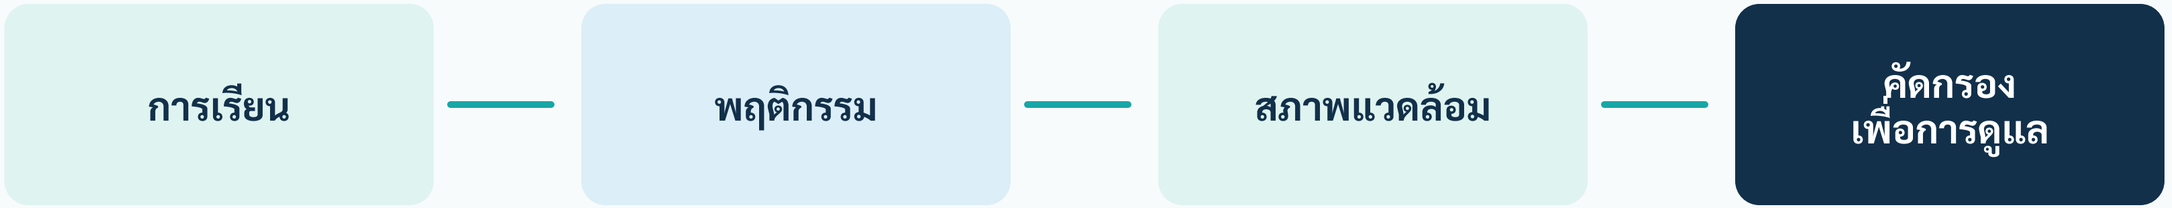
ระบบทำนายความเสี่ยงการออกกลางคันของนักศึกษา

คุณานนท์ มาลยานนท์ 6810450807
กฤตภาส สุขประสงค์ 6810450718



ที่มาและความสำคัญ

ข้อมูลหลายด้านช่วยให้เห็นความเสี่ยงร่วมกัน — ก่อนปัญหาจะสายเกินไป



ผลทำนายเป็นสัญญาณเพื่อพิจารณาและติดตามเพิ่มเติม ไม่ใช่คำตัดสิน

วัตถุประสงค์และผู้ใช้งาน

สร้างระบบจำแนกความเสี่ยง พร้อมหน้าจอใช้งาน

เปรียบเทียบ 3 โมเดล
Logistic Regression · Decision Tree · Random Forest

ผู้ใช้เป้าหมาย

อาจารย์ที่ปรึกษา และเจ้าหน้าที่ดูแลนักศึกษา

ประเมินด้วยข้อมูล Test ที่แยกไว้

ภาพรวมชุดข้อมูล

800
แถว

25
คอลัมน์ก่อนคัดเลือก

17–25
ปี

1–4
ชั้นปี

17
input features

ไฟล์ในโปรเจกต์: data/raw/dataset.csv · เป้าหมาย: Dropout_Risk
ยังไม่มีลิงก์ผู้เผยแพร่ต้นทางในเอกสารโปรเจกต์

กลุ่มข้อมูลนำเข้า — 17 ตัวแปร

พื้นฐาน

อายุ · ชั้นปี · สาขา · ที่พัก

การเรียน

การเข้าเรียน · ชั่วโมงอ่านหนังสือ · GPA · วิชาค้าง

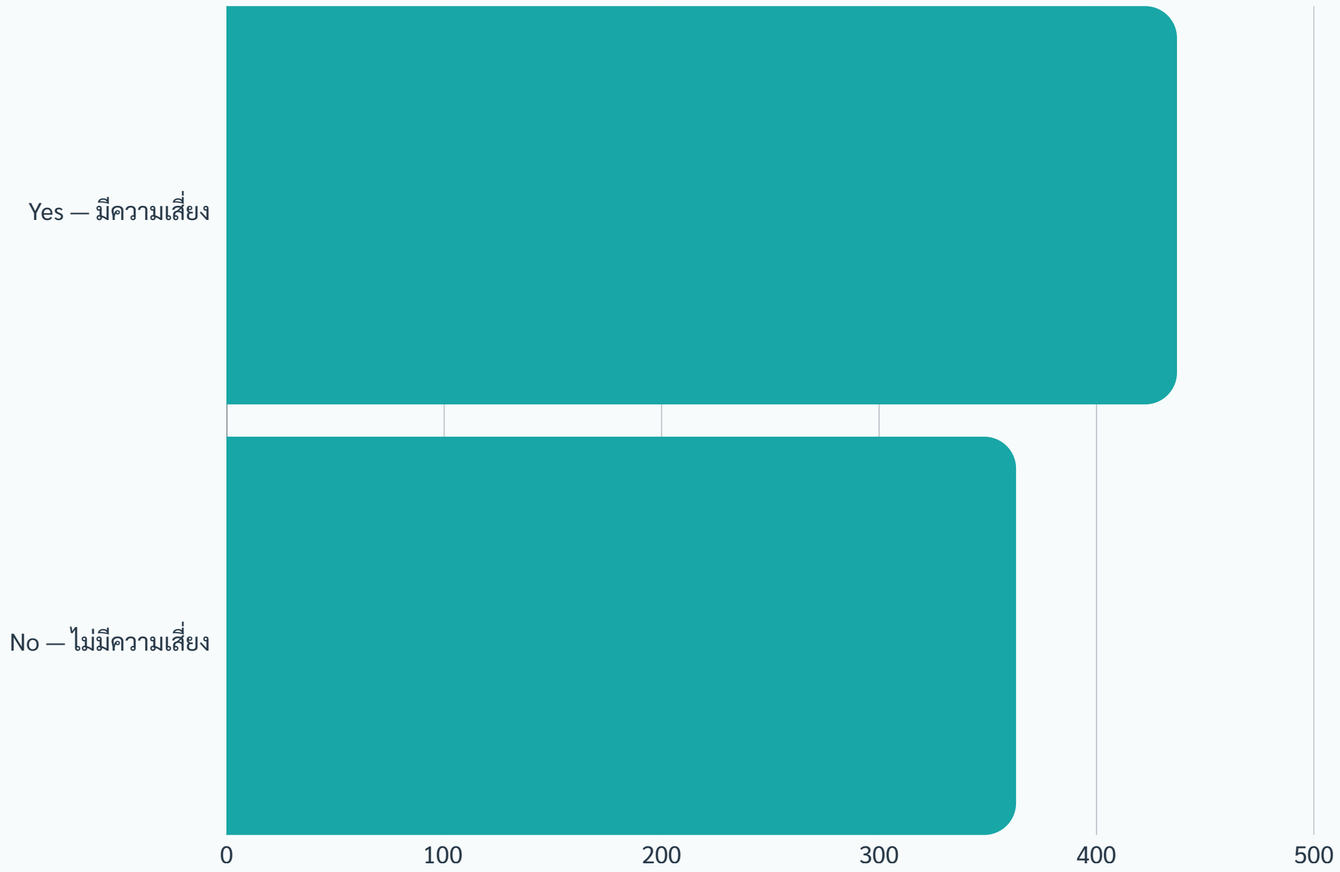
พฤติกรรมและเศรษฐกิจ

เวลาใช้หน้าจอ · งานพิเศษ · รายได้ครอบครัว

การสนับสนุน

ความเครียดการเงิน · ครอบครัว · ความเครียด · ความกังวล
แรงจูงใจ · การเข้าถึงคำปรึกษา

สิ่งที่ต้องการทำนาย



54.63%

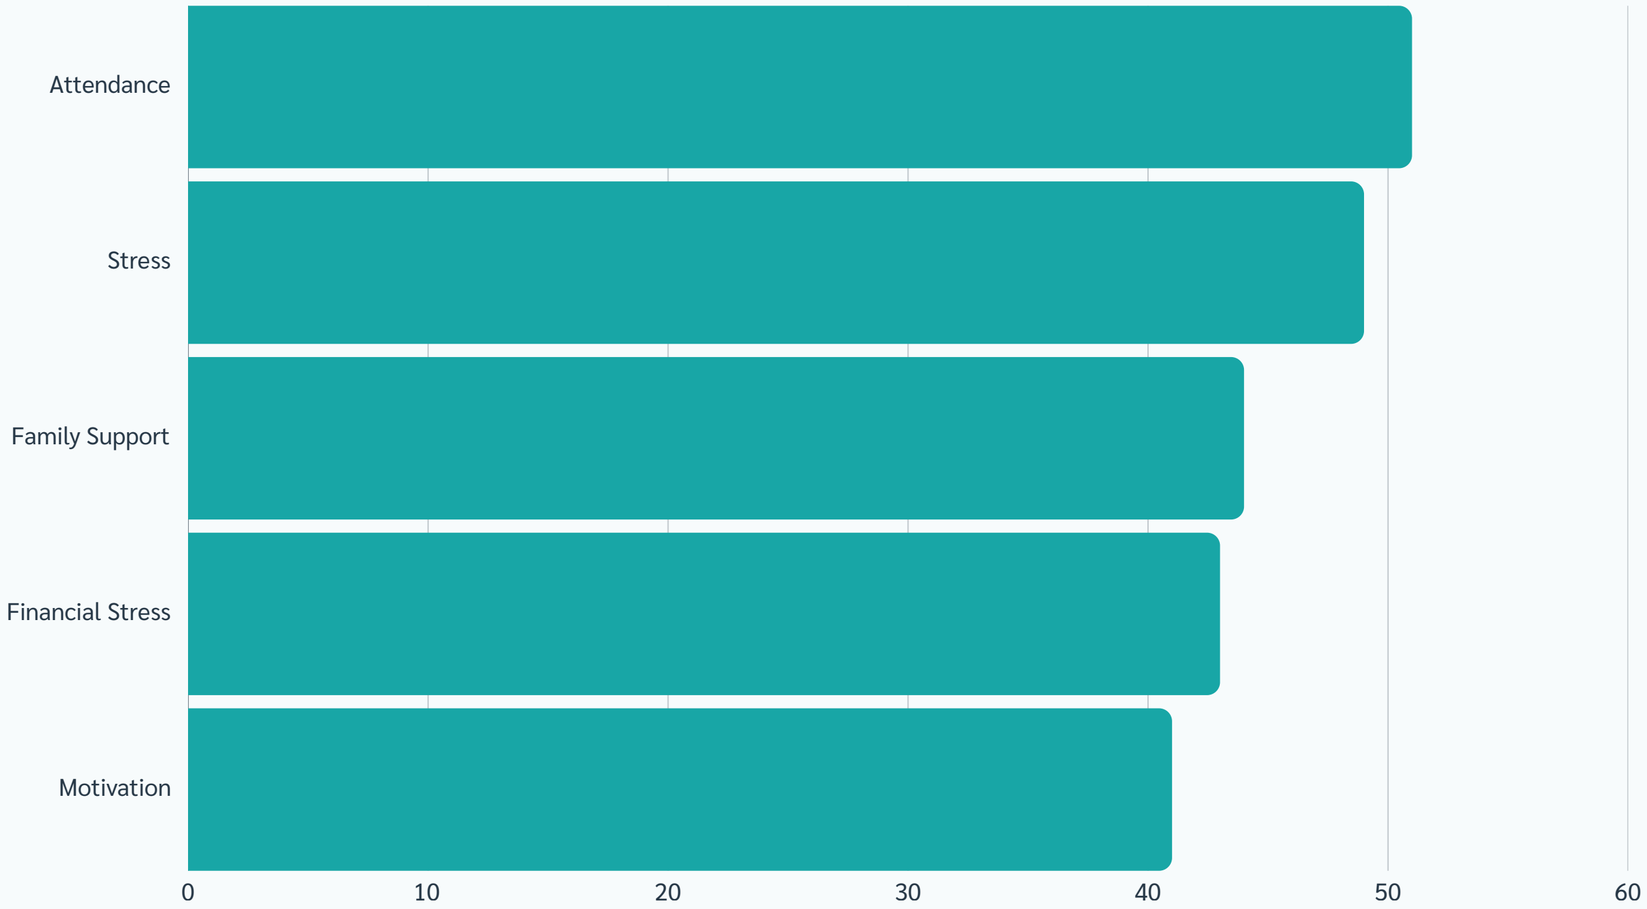
437 คน ถูกระบุว่า Yes

Binary Classification

label ความเสี่ยงไม่ใช่หลักฐานยืนยันการออกกลางคันจริง

แหล่งผล: data/raw/dataset.csv

คุณภาพของข้อมูล



0

แถวซ้ำ และ Student_ID ซ้ำ

เติมค่าภายใน Pipeline

แหล่งผล: data/raw/dataset.csv · การตรวจคุณภาพข้อมูลใน notebook

การคัดเลือกตัวแปร

24 ตัวแปร
ที่ไม่ใช่เป้าหมาย

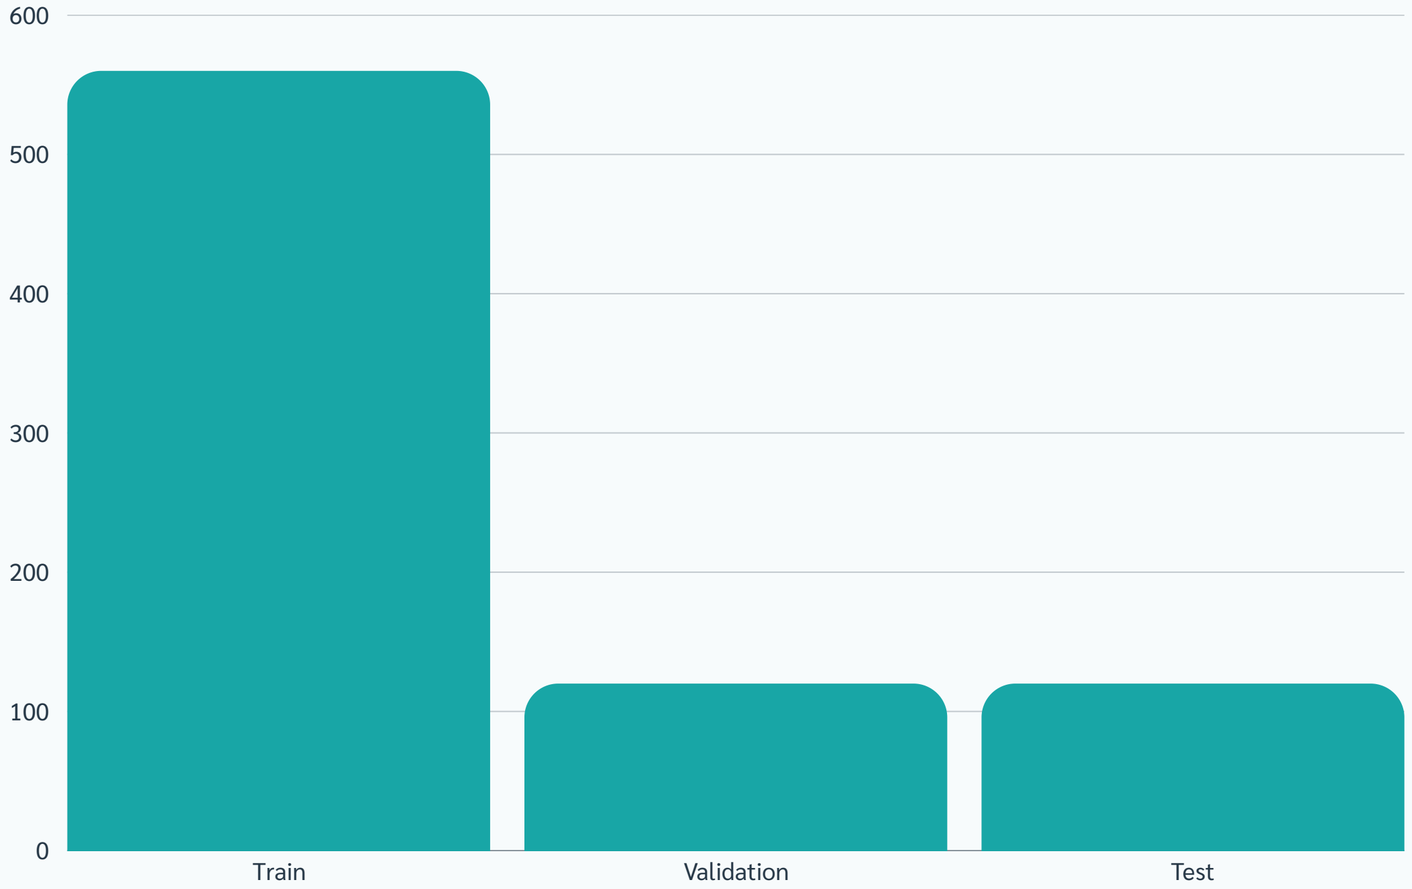
17 ตัวแปร
ที่ใช้จริง

ตัดออก

Student_ID — รหัสเฉพาะบุคคล
Gender — ลดการใช้ข้อมูลเพศโดยตรง
Burnout_Level — ถือเป็นอีกผลลัพธ์หนึ่ง
Sleep · Exercise · Social Activity · Peer Pressure — ลดภาระการกรอก

การตัด Gender ออก ยังไม่พิสูจน์ว่าโมเดลปราศจาก bias

การแบ่ง Train / Validation / Test



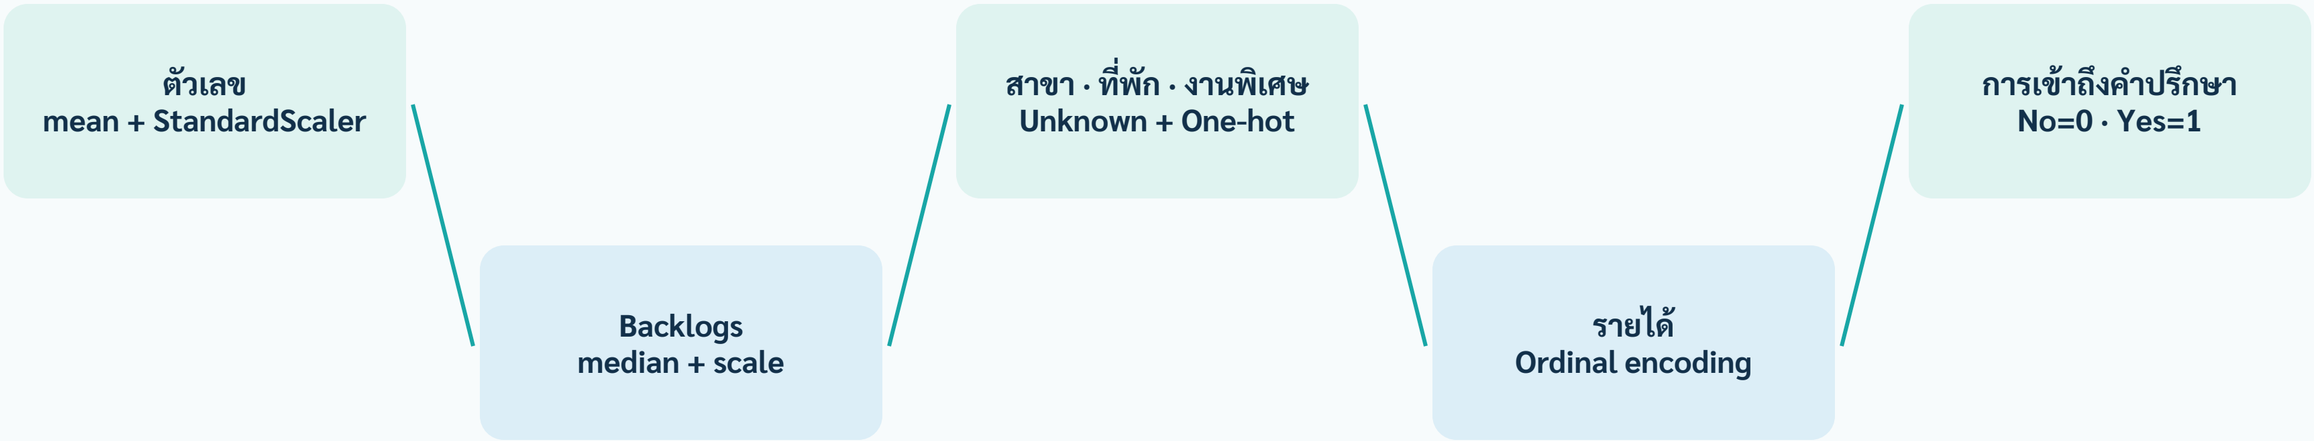
70%

15% + 15%

แบ่งก่อน fit preprocessing
ใช้ stratify ตาม label
random_state = 42
Validation เลือกโมเดล · Test ประเมินสุดท้าย

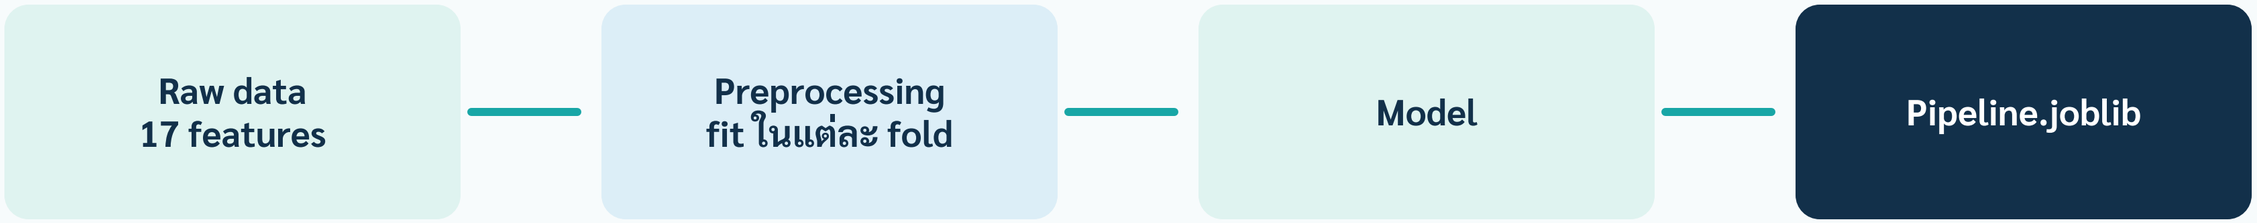
แหล่งผล: การแบ่งชุดข้อมูลใน new_notebook

การเตรียมคุณลักษณะ



จัดการตามชนิดตัวแปร แล้วส่งต่อเข้าโมเดลในเส้นทางเดียวกัน

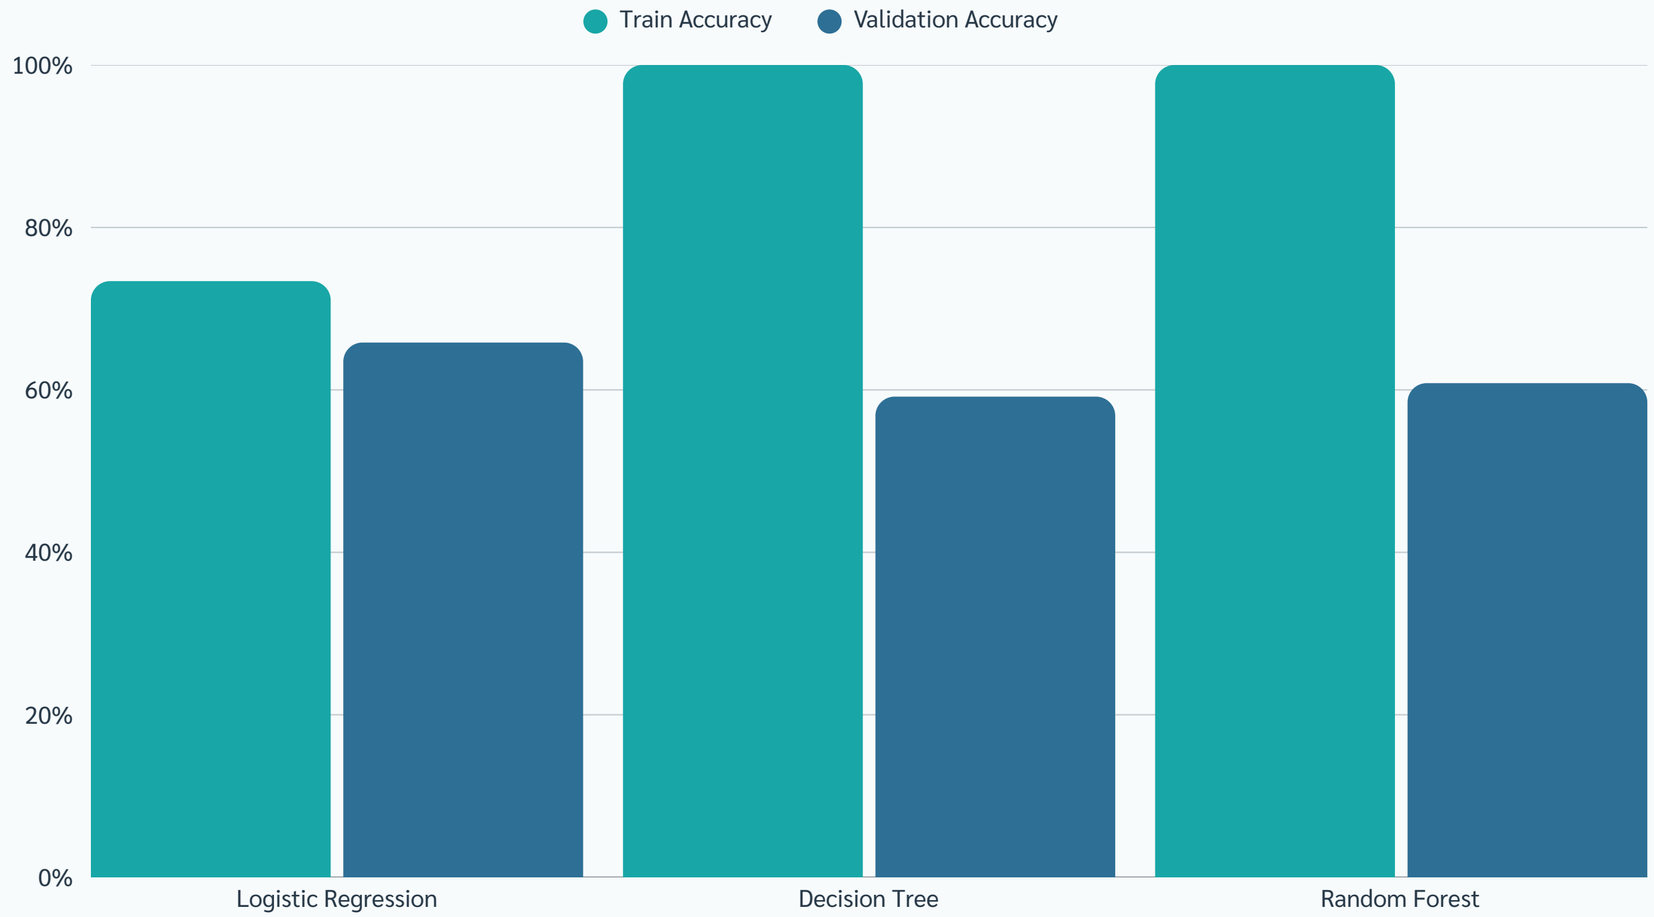
Pipeline และการป้องกัน Data Leakage



17 → 28 features

ไม่เหลือ NaN หลัง preprocessing
ค่าที่ใช้เติมและ scale เรียนรู้จาก training fold เท่านั้น

ผลโมเดลเบื้องต้น



ช่องว่างสูง

โมเดลต้นไม้จำ Train ได้ 100% แต่ Validation ลดลงมาก
จึงต้องควบคุมความซับซ้อน

แหล่งผล: new_notebook/2–6 · Train/Validation ก่อน tuning

Hyperparameter Tuning

Logistic Regression

71.25%

C=0.01
ทดลอง C 6 ค่า

Decision Tree

63.21%

depth=10 · leaf=10 · split=2
30 ชุด

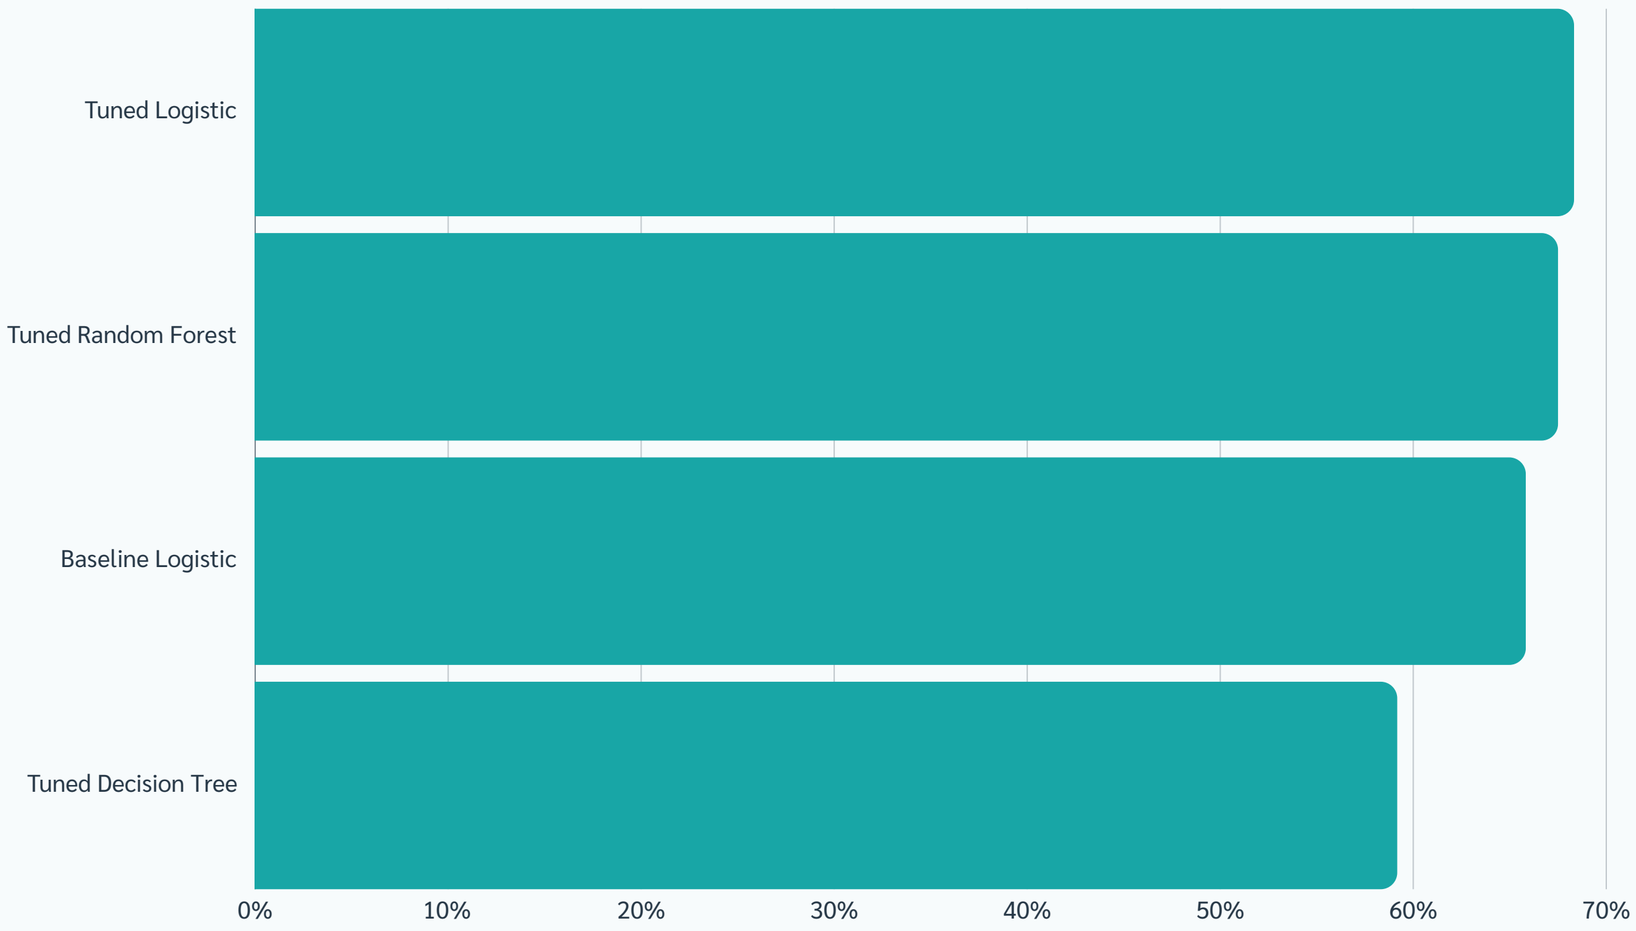
Random Forest

71.07%

100 trees · depth=5 · split=10
leaf=1 · max_features=sqrt
40 ชุด

RandomizedSearchCV · 5-fold · scoring='accuracy' | CV score เป็นผลบน Train folds ไม่ใช่ Test score

การเลือกโมเดลสุดท้าย



เลือก
Tuned Logistic Regression

C = 0.01

fit ใหม่ด้วย Train + Validation
รวม 680 คน
แล้วประเมิน Test 120 คน

แหล่งผล: new_notebook/2–6 · Validation Accuracy หลัง tuning

ผลประเมินบน Test

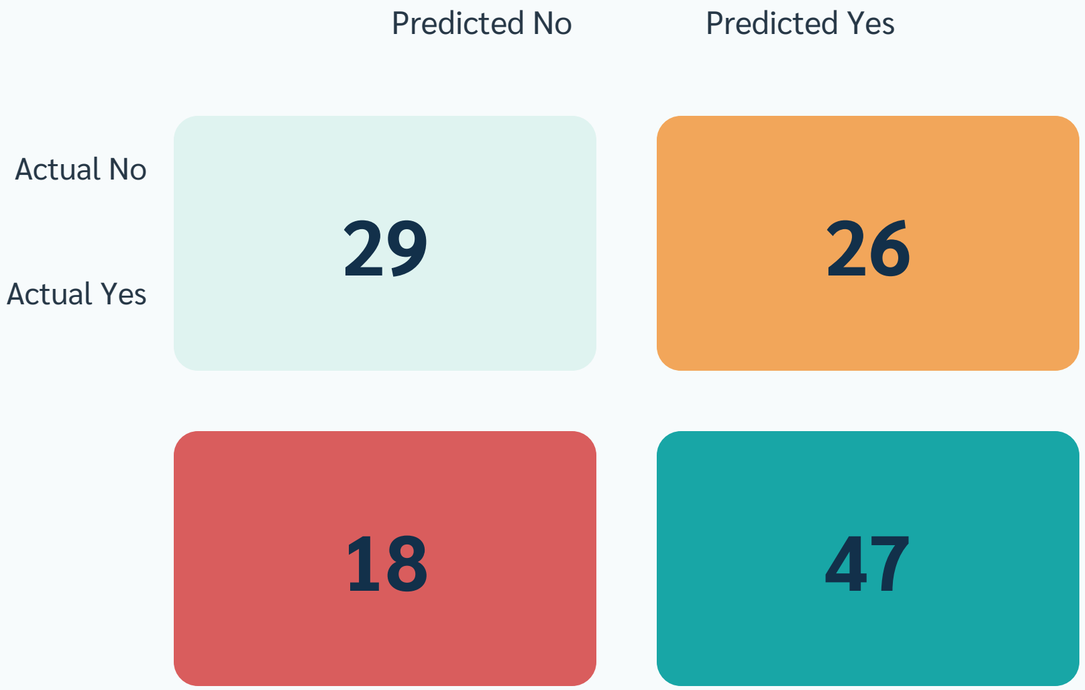
63.33%

Accuracy · ทำนายถูก 76 จาก 120 คน

กลุ่ม Yes
Precision 64.38% · Recall 72.31% · F1 68.12%

พลาด Yes 18 คน · เตือน No เป็น Yes 26 คน

Confusion Matrix



แหล่งผล: new_notebook/2–6 · Test set 120 คน

ข้อจำกัดของผลลัพธ์

ใช้เพื่อช่วยคัดกรอง
และสนับสนุน

ไม่ใช้ตัดสินสิทธิ
ของนักศึกษาโดยลำพัง

Test เพียง 120 คน · ยังไม่ยืนยันกับสถาบันจริง · เตือนผิด 26 คน · พลาดกลุ่ม Yes 18 คน
การตัด Gender ไม่เท่ากับการตรวจความเป็นธรรมครบถ้วน

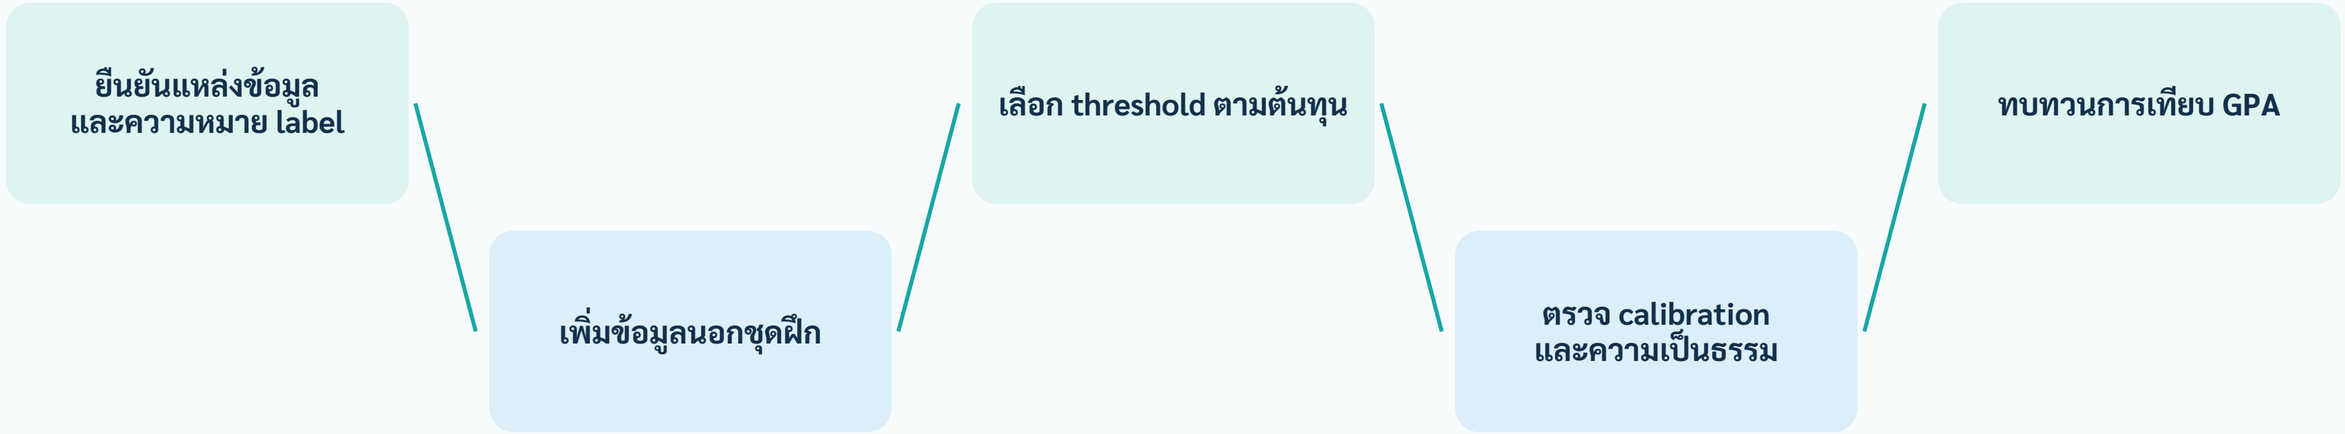
การใช้งาน Streamlit

1 กรอกข้อมูล 17 ตัวแปร — 2 Previous GPA 0–4 — 3 กด Predict — ผล: Yes หรือ No

เบื้องหลัง: GPA × 2.5

ตัวอย่าง 2.80 → 7.00 ก่อนเข้า Pipeline · เป็นการเทียบสเกลเชิงเส้น

แนวทางพัฒนาต่อ



ปรับปรุงข้อมูลและการประเมิน ก่อนใช้งานจริง

ผู้จัดทำ

Student Dropout Prediction

6810450807 คุณานนท์ มาลยานนท์

6810450718 กฤตภาส สุขประสงค์

การใช้ AI และแหล่งอ้างอิง

AI ช่วยปรับ UI และเรียบเรียงสไลด์ จากหลักฐานในโปรเจกต์

Codex — ปรับช่อง GPA และช่วยจัดเนื้อหา
Canva AI — ช่วยจัดรูปแบบสไลด์

ข้อมูล

data/raw/dataset.csv

ขั้นตอนและผล

new_notebook/2–6

ระบบ

deployment/app.py + Pipeline

ควรตรวจสอบตัวเลขและเนื้อหาก่อนนำเสนอ