Predicting Employee Attrition

การคาดการณ์การลาออกของพนักงาน

ที่มาและความสำคัญของระบบ



ที่มาของระบบ

ในยุคที่การแข่งขันทางธุรกิจสูงและสภาพแวดล้อมของการทำงานเปลี่ยนแปลงอย่างรวดเร็ว การมีบุคลากรที่มีความรู้ ความสามารถ และมีความผูกพันกับองค์กรเป็นสิ่งที่หน่วยงานให้ความสำคัญ อย่างไรก็ตาม ปัญหาที่พบได้บ่อยและสร้างผลกระทบอย่างมากต่อองค์กร คือ **การลาออกของพนักงาน (Employee Attrition)** เพราะไม่เพียงแต่หมายถึงการขาดแรงงาน แต่ยังส่งผลต่อประสิทธิภาพการทำงานโดยรวม องค์กรต้องเผชิญกับต้นทุนแฝงจำนวนมาก ไม่ว่าจะเป็นค่าใช้จ่ายในการหาบุคลากรใหม่ การฝึกอบรมพนักงาน การปรับตัวของทีมงาน และเวลาในการทำให้พนักงานใหม่สามารถทำงานได้เต็มประสิทธิภาพ

ปัญหาการลาออกจึงไม่ใช่เพียงประเด็นทางบุคคล แต่เป็นประเด็นเชิงกลยุทธ์ที่สะท้อนถึงความมั่นคงและความสามารถในการบริหารจัดการขององค์กร การเข้าใจและสามารถคาดการณ์แนวโน้มการลาออกของพนักงานได้ล่วงหน้าจึงเป็นสิ่งสำคัญอย่างยิ่ง เพราะจะช่วยให้องค์กรสามารถวางแผนเชิงรุกในการดูแลพนักงานได้อย่างมีประสิทธิภาพ

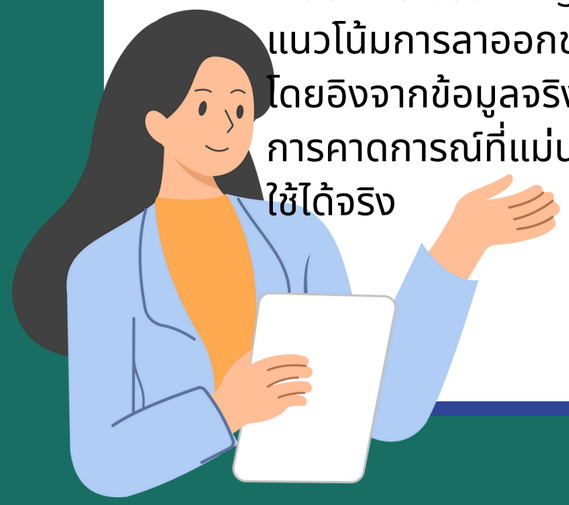
วัตถุประสงค์



วัตถุประสงค์

พัฒนาระบบคาดการณ์การลาออกของพนักงาน

สร้างระบบต้นแบบที่ใช้เทคนิค Machine Learning ในการทำนายแนวโน้มการลาออกของพนักงาน โดยอิงจากข้อมูลจริง เพื่อให้ได้ผลการคาดการณ์ที่แม่นยำและนำไปใช้ได้จริง



สนับสนุนการตัดสินใจของฝ่ายทรัพยากรบุคคล (HR)

นำผลการคาดการณ์มาใช้เป็นเครื่องมือช่วยตัดสินใจในการดูแลพนักงาน เช่น การวางแผนดูแลกลุ่มพนักงานที่มีความเสี่ยงลาออก การออกแบบสวัสดิการ

พัฒนาระบบแสดงผลและรายงานข้อมูล (Dashboard)

ออกแบบส่วนแสดงผลที่นำเสนอข้อมูลการคาดการณ์และสถิติเกี่ยวกับการลาออกของพนักงานในรูปแบบกราฟหรือแผนภูมิ เพื่อให้ผู้บริหารและ HR เข้าใจข้อมูลได้ง่ายและเห็นภาพรวมขององค์กร

ที่มาและรายละเอียดของข้อมูล



ที่มาและรายละเอียดของข้อมูล

จาก Kaggle โดยผู้ใช้ชื่อ pavansubhasht



ชุดข้อมูล **IBM HR Analytics Employee Attrition Dataset** เป็นชุดข้อมูลจำลองที่สร้างโดยนักวิทยาศาสตร์ข้อมูลของ IBM เพื่อใช้ในการวิเคราะห์ปัจจัยที่ส่งผลต่อการลาออกของพนักงาน (Employee Attrition) และฝึกฝนการสร้างโมเดลทำนายพนักงานที่อาจลาออก

ข้อมูลครอบคลุมทั้งข้อมูลส่วนบุคคล ตำแหน่งงาน ผลการปฏิบัติงาน และสภาพแวดล้อมในการทำงาน พร้อมตัวแปรเป้าหมาย Attrition ที่ระบุว่าพนักงานลาออกหรือไม่ ชุดข้อมูลนี้ช่วยให้นักวิเคราะห์สามารถสำรวจแนวโน้มต่าง ๆ และนำไปใช้ฝึกการวิเคราะห์เชิงลึกได้อย่างสะดวก

รายละเอียดสิ่งที่ต้องการทำนาย



รายละเอียดของ
สิ่งที่ต้องการทำนาย

โมเดลจะทำนายปัญหาชนิด Binary Classification โดย เฉลย(Label) ของระบบคือ Attrition ใช้เพื่อระบุว่าพนักงาน ลาออกจากองค์กรหรือไม่

แบ่งออกเป็น 2 กลุ่ม ได้แก่

1.yes

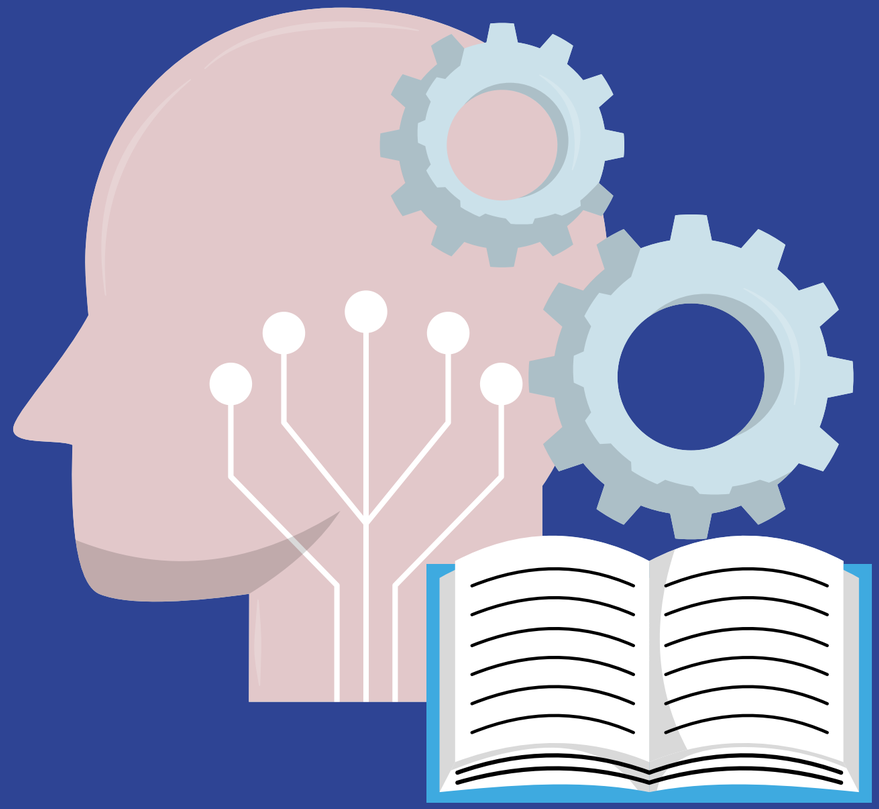
-พนักงานที่มีแนวโน้มจะลาออก

2.no

-พนักงานที่มีแนวโน้มจะอยู่ต่อ



Training Data



Training Data

-ลบคอลัมน์ที่ไม่จำเป็น

เลือกคอลัมน์ที่ไม่ต้องใช้สำหรับโมเดล
เพื่อลด noise และไม่ให้โมเดลเรียนรู้
ข้อมูลไม่สำคัญ

EX. Education,
Gender,MaritalStatus,
NumCompaniesWorked,
TrainingTimesLastYear,
YearsWithCurrManager,
TotalWorkingYears,
EmployeeCount, Over18,
StandardHours, EmployeeNumber

-แบ่งข้อมูล Training/Test

ใช้ train_test_split แบ่ง df_employee เป็น
Training Data → 80%
Test Data → 20%
และ stratify ทำให้สัดส่วนของ Attrition เหมือน
ต้นฉบับ

-แยก Features และ Target

X_train, X_test → ข้อมูล input
y_train, y_test → Target
(Attrition)

Feature Engineering



Feature Engineering

-Class Imbalance

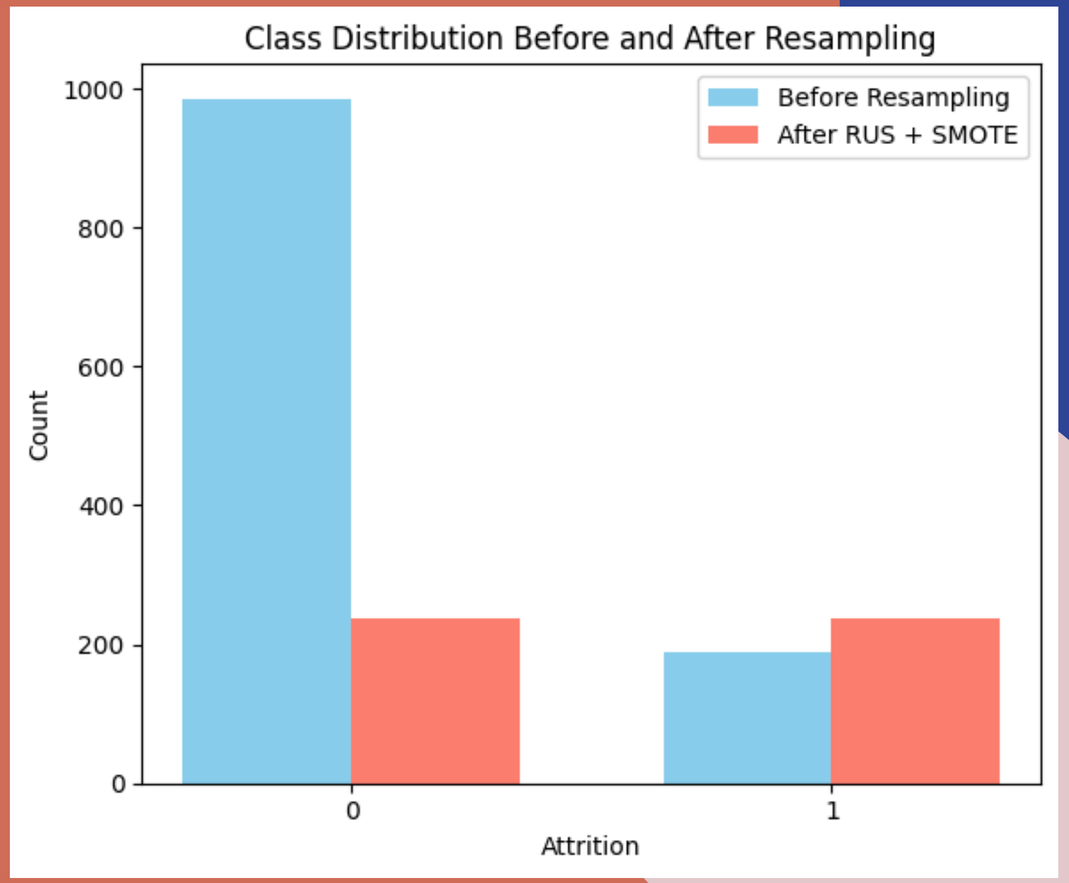
ใน dataset ของพนักงานสำหรับทำนาย Attrition เราพบว่า จำนวนพนักงานที่ลาออก (Yes) มีจำนวนน้อยมาก เมื่อเทียบกับพนักงานที่ไม่ลาออก (No)

ใช้ **-SMOTE**

-Under-Sampler

หากเราใช้ SMOTE เพียงอย่างเดียว เพื่อสร้างตัวอย่างใหม่ของคลาสที่น้อย (Yes) ให้สมดุลกับ No ข้อมูลจะขยายตัวขึ้นอย่างมาก ทำให้ dataset มีขนาดใหญ่เกินไป และอาจทำให้โมเดล overfitting กับตัวอย่างสังเคราะห์

ดังนั้นจึงใช้ Random Under-Sampler ร่วมด้วย เพื่อลดจำนวนตัวอย่างของคลาสที่มากเกินไป (No) ให้ใกล้เคียงกับ Yesหลังจากนั้นจึงใช้ SMOTE สร้างตัวอย่างใหม่ของ Yes ให้ dataset กลับมาสมดุล



Feature Engineering

-แยกคอลัมน์ตามชนิดข้อมูล

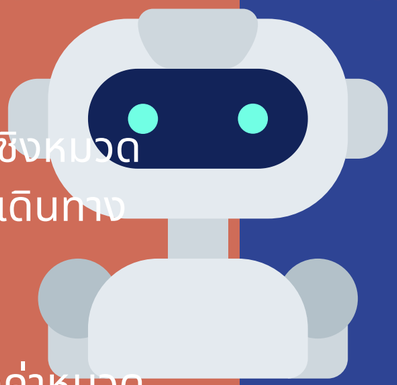
ในการเตรียมข้อมูล เราได้ทำการแยกคอลัมน์ออกเป็นสองประเภท ได้แก่

• **Numeric Features** ซึ่งเป็นข้อมูลเชิงตัวเลขที่มีความหมายเชิงปริมาณ เช่น อายุ รายได้ หรือจำนวนปีทำงาน

-ทำการ **Standardization** เพื่อปรับค่าตัวเลขให้อยู่ในช่วงเดียวกัน โดยทำให้มีค่าเฉลี่ยเท่ากับ 0 และส่วนเบี่ยงเบนมาตรฐานเท่ากับ 1
วิธีนี้ช่วยให้โมเดลไม่ให้ความสำคัญกับตัวแปรที่มีขนาดตัวเลขใหญ่เกินไป

• **Categorical Features** ซึ่งเป็นข้อมูลเชิงหมวดหมู่หรือระดับ เช่น เพศ แผนก ประเภทการเดินทาง และระดับความพึงพอใจ

-ใช้ One-Hot Encoding เพื่อแปลงค่าหมวดหมู่ให้เป็นตัวเลขในรูปแบบ 0 และ 1
โดยสร้างคอลัมน์ใหม่แทนแต่ละหมวดหมู่ เช่น “Gender” จะถูกแปลงเป็น “Gender_Male” และ “Gender_Female”
ทำให้โมเดลสามารถนำข้อมูลเหล่านี้ไปใช้ในการเรียนรู้ได้อย่างถูกต้อง

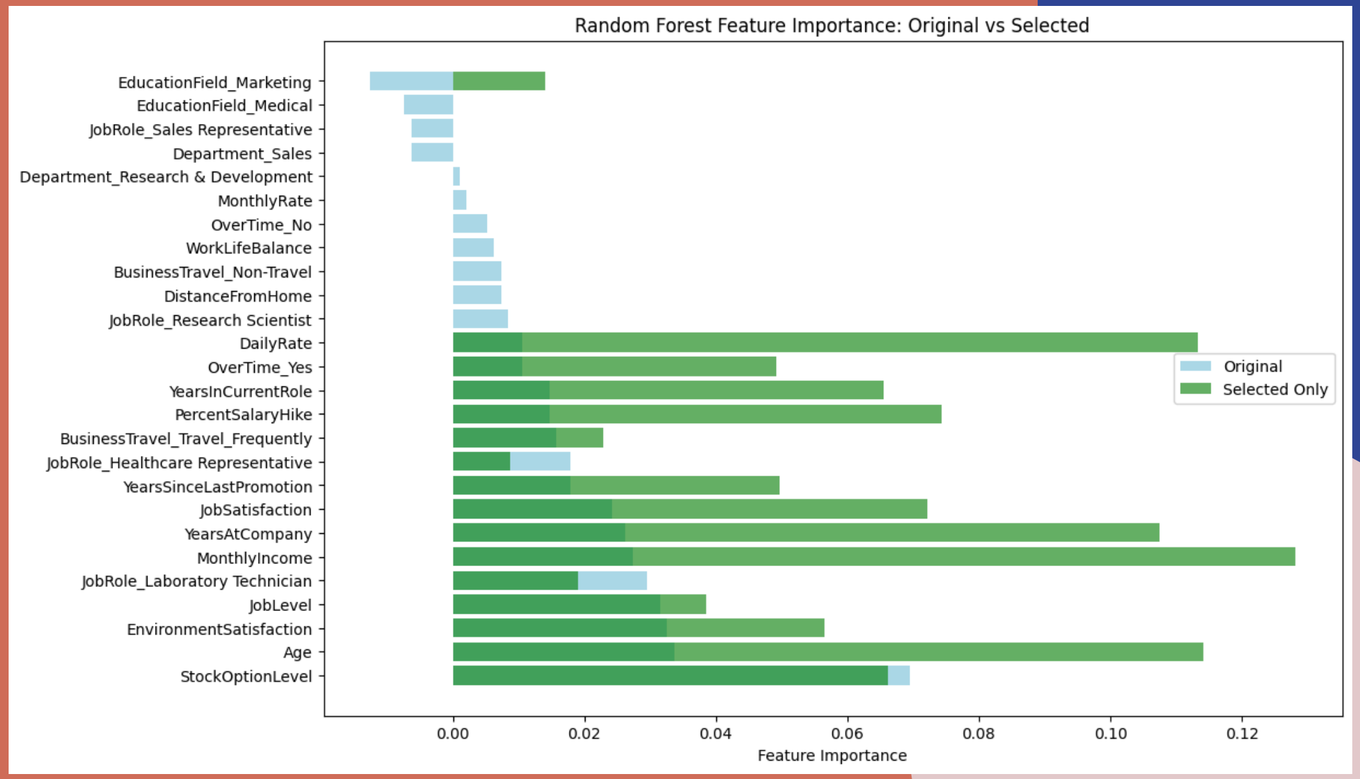


Feature Engineering

-Feature Importance

ใช้เพื่อหาว่าคุณลักษณะใดของพนักงานมีผลต่อการทำนายการลาออกมากที่สุด โดยในที่นี้ใช้วิธี **Permutation Importance** ซึ่งเป็นการวัดความสำคัญของตัวแปรโดยอาศัยผลกระทบต่อความแม่นยำของโมเดล

-Permutation Importance คือ เมื่อทำการสลับค่าของฟีเจอร์ใดฟีเจอร์หนึ่งแบบสุ่ม หากค่าความแม่นยำของโมเดลลดลงอย่างมีนัยสำคัญ แสดงว่าฟีเจอร์นั้นมีความสำคัญต่อการทำนายสูง ในทางกลับกัน หากผลลัพธ์ไม่เปลี่ยนมาก แสดงว่าฟีเจอร์นั้นมีอิทธิพลน้อยต่อการพยากรณ์ผลลัพธ์ เป็นการช่วยให้สามารถคัดเลือกเฉพาะฟีเจอร์ที่มีผลต่อการลาออกจริง ๆ



กระบวนการเลือกอัลกอริทึมที่ทดลองและใช้งาน



Model Development

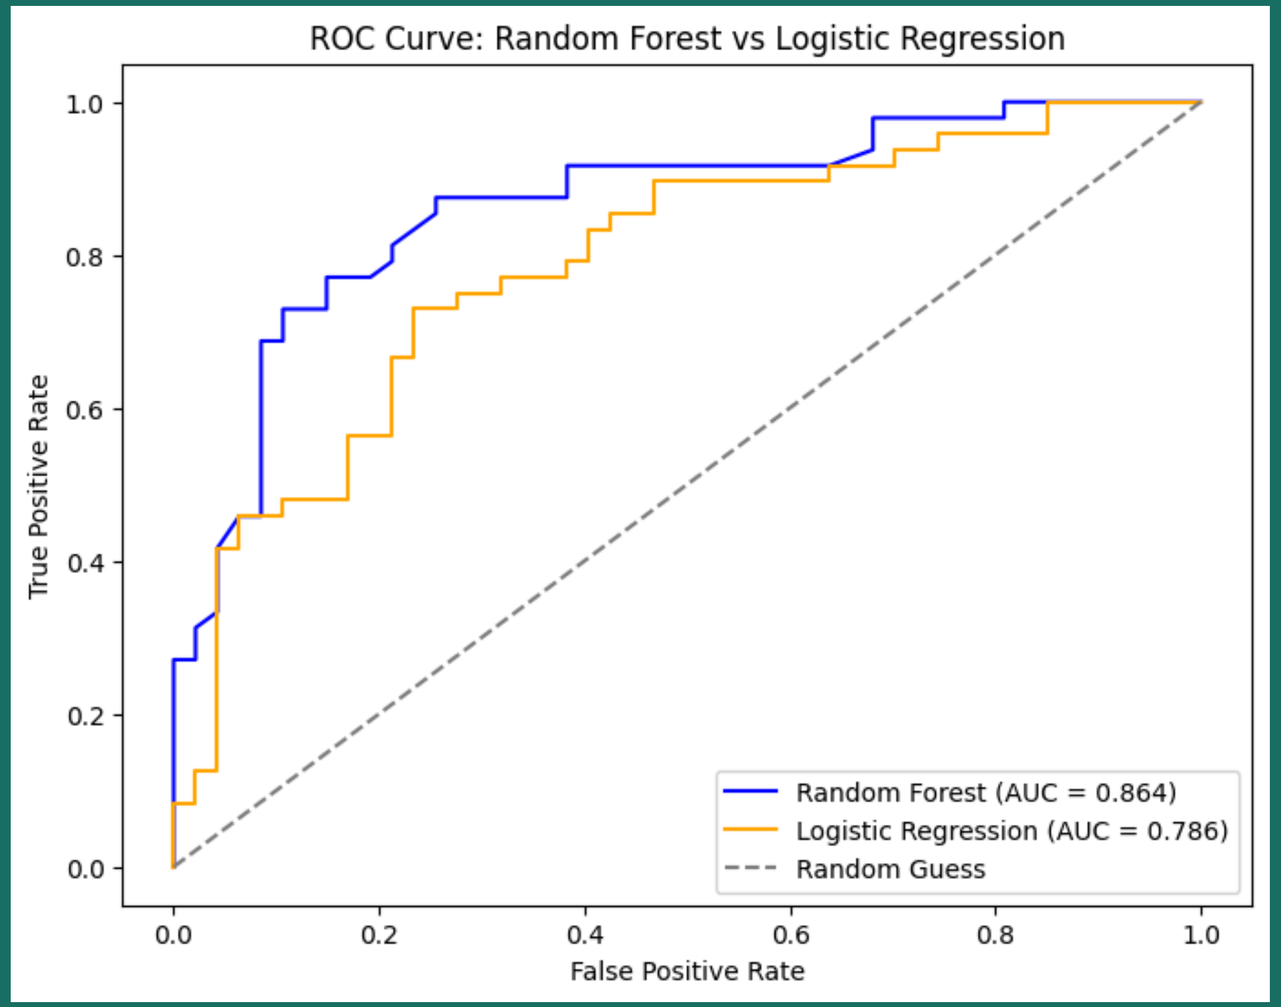
Random Forest

เป็นโมเดลที่รวมหลายต้นไม้ตัดสินใจเข้าด้วยกัน เพื่อเพิ่มความแม่นยำและลดความผิดพลาด เหมาะกับข้อมูลที่ซับซ้อนและมีความไม่สมดุล สามารถระบุปัจจัยสำคัญที่มีผลต่อการลาออกได้ แม้จะใช้ทรัพยากรมากกว่าโมเดลพื้นฐาน แต่ให้ผลลัพธ์ที่แม่นยำและเสถียรกว่า จึงเหมาะสำหรับการใช้งานจริงในองค์กร

Logistic Regression

เป็นโมเดลเชิงสถิติที่เข้าใจง่าย สามารถตีความผลได้ชัดเจนว่าปัจจัยใดมีผลต่อโอกาสการลาออก ทำงานรวดเร็ว ใช้ทรัพยากรน้อย เหมาะกับการใช้งานเบื้องต้นหรือเป็นโมเดลพื้นฐานในการเปรียบเทียบ แต่ความแม่นยำอาจลดลงเมื่อข้อมูลมีความซับซ้อนหรือมีความสัมพันธ์แบบไม่เป็นเชิงเส้น

Model Development



กราฟ ROC ใช้ประเมินความสามารถของโมเดลในการทำนายผลลัพธ์แบบสองทาง โดยดูจากความสัมพันธ์ระหว่างอัตราทำนายถูก (TPR) และอัตราทำนายผิด (FPR)

จากผลของกราฟพบว่า

- Random Forest (AUC = 0.864) มีประสิทธิภาพดีกว่า
- Logistic Regression (AUC = 0.786) ทำได้ดีแต่แม่นยำน้อยกว่า

Model Development

final model

“ Random Forest ”

หลังจากทดลองทั้ง Logistic Regression และ Random Forest พบว่า Random Forest ให้ความแม่นยำสูงกว่าและเสถียรกว่า จัดการข้อมูลที่ซับซ้อนได้ดี สามารถวิเคราะห์ความสำคัญของปัจจัยต่าง ๆ ที่ส่งผลต่อการลาออก ทำให้เข้าใจรูปแบบข้อมูลได้ชัดเจน และมีประสิทธิภาพที่ดีกว่าในการทำนาย



กระบวนการ และ ผลการประเมิน



Hyperparameter

- เป็น จำนวนต้นไม้ (trees) ที่ Random Forest จะสร้างแล้วเอาผลลัพธ์มารวมกัน (voting) เพื่อให้การทำนายแม่นยำขึ้น
  n_estimators : 100
- เป็น การตั้งค่า seed สำหรับ random number generator
  random_state : 42



Baseline

ใช้ DummyClassifier

ในการสร้าง baseline หลายรูปแบบ

Uniform

โมเดลนี้จะ สุ่มทายทุกคลาสเท่ากัน ผลลัพธ์คือ

- Training Accuracy: 48.64%
- Test Accuracy: 50.21%

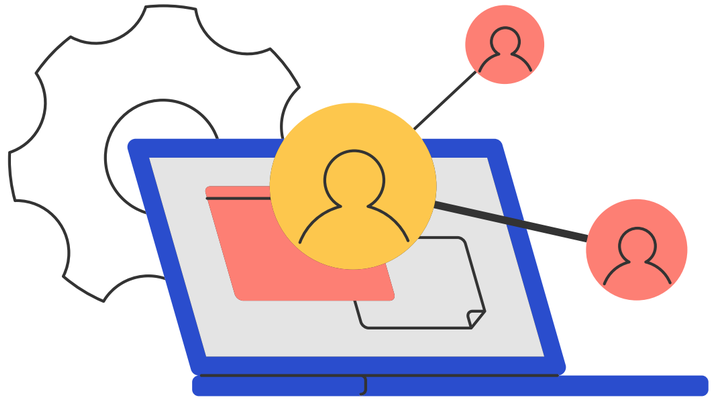
การสุ่มแบบ uniform ไม่ได้เรียนรู้จากข้อมูลใด ๆ Accuracy จึงใกล้เคียงกับ 50% เป็น baseline แบบสุ่มล้วน ใช้เป็นตัวเปรียบเทียบว่าการเดาล้วนได้ผลเพียงครึ่งหนึ่งเท่านั้น

Stratified

โมเดลนี้จะ สุ่มทายแต่ละคลาสตามสัดส่วนที่เกิดขึ้นจริงในชุด train ผลลัพธ์คือ

- Training Accuracy: 50.15%
- Test Accuracy: 52.32%

การทายตาม distribution ของข้อมูลช่วยให้ Accuracy ดีขึ้นเล็กน้อยกว่าแบบ Most Frequent และ Uniform แต่ยังถือว่าเป็น baseline แบบสุ่ม ที่ใช้เปรียบเทียบโมเดลจริง



Baseline

ใช้ DummyClassifier

ในการสร้าง baseline หลายรูปแบบ

Constant = 0

โมเดลนี้จะทายค่าเดียวตลอด คือ 0 (ไม่ลาออก) ผลลัพธ์คือ

- Training Accuracy: 49.55%
- Test Accuracy: 50.63%

การทายค่าเดียวไม่ช่วยให้โมเดลทำนายคลาส 1 (ลาออก) ได้ดี Accuracy จึงต่ำ

Most Frequent

โมเดลนี้จะทายคลาสที่เกิดบ่อยที่สุด ในชุดข้อมูล train เสมอ สำหรับ dataset ของเราที่ balanced (พนักงานลาออกและไม่ลาออกใกล้เคียงกัน) ผลลัพธ์คือ

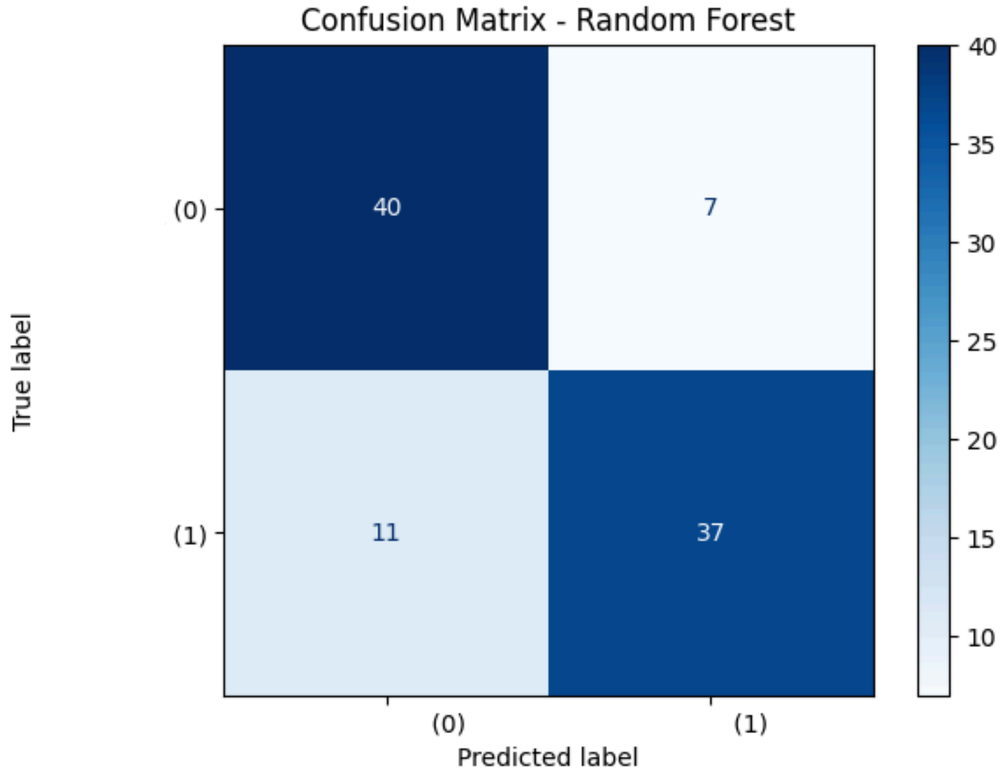
- Training Accuracy: 50.45%
- Test Accuracy: 49.37%

การทายคลาสที่เจอบ่อยที่สุดไม่ช่วยให้ Accuracy สูงมาก เพราะ dataset ไม่มีคลาสใดเด่นชัด โมเดลนี้จึงทำหน้าที่เป็น baseline ที่ง่ายที่สุด

ทุก strategy ของ DummyClassifier ให้ Test Accuracy ประมาณ 50% เพราะ dataset สมดุลและโมเดลไม่เป็นการเดาสุ่ม

ผลการประเมินโมเดล

Confusion Matrix

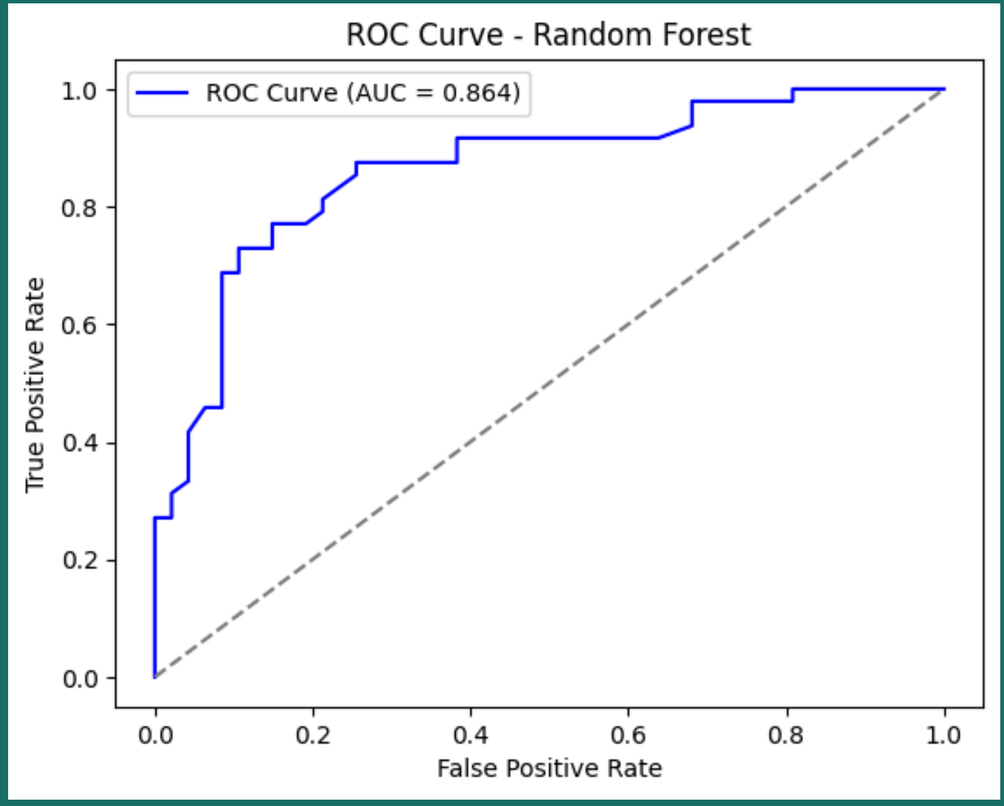


- **ไม่ลาออก (0): โมเดลทำนายถูก 40 / 47 คน (~85%)**
- **ลาออก (1): โมเดลทำนายถูก 37 / 48 คน (~77%)**
- **โมเดล Random Forest ทำนายได้ถูกส่วนใหญ่ ทั้งคลาสลาออกและไม่ลาออก มีข้อผิดพลาดเพียงเล็กน้อย แสดงว่าโมเดลมีความแม่นยำและสมดุลดี**

ผลการประเมินโมเดล

- **Accuracy = 0.811 (81.05%)** โมเดลทำนายถูกประมาณ **81%** ของทั้งหมด

- **Precision = 0.841 (84.09%)**
- **Recall = 0.771 (77.08%)**
- **F1-Score = 0.804 (80.43%)**
- **AUC = 0.864 (86.39%)**
- **Cohen’s Kappa = 0.621 (62.13%)**
- **MCC = 0.624 (62.36%)**
- **Balanced Accuracy = 0.811 (81.09%)**
- **Cross-Validation Mean = 0.705 (70.49%)**





System Usage Guide

User Interface in hugging face



Age 18 ↺

18 60

Monthly Income (บาท)

0

Years At Company 0 ↺

0 40

Years In Current Role 0 ↺

0 20

Job Satisfaction

1 - Bad (แย่สุด)

Environment Satisfaction

1 - Bad (แย่สุด)

Job Level

Entry-level (Staff / New Grad)

Do you often work overtime?

Yes

Business Travel (ครั้ง/เดือน)

Never travel (0 ครั้ง/เดือน)

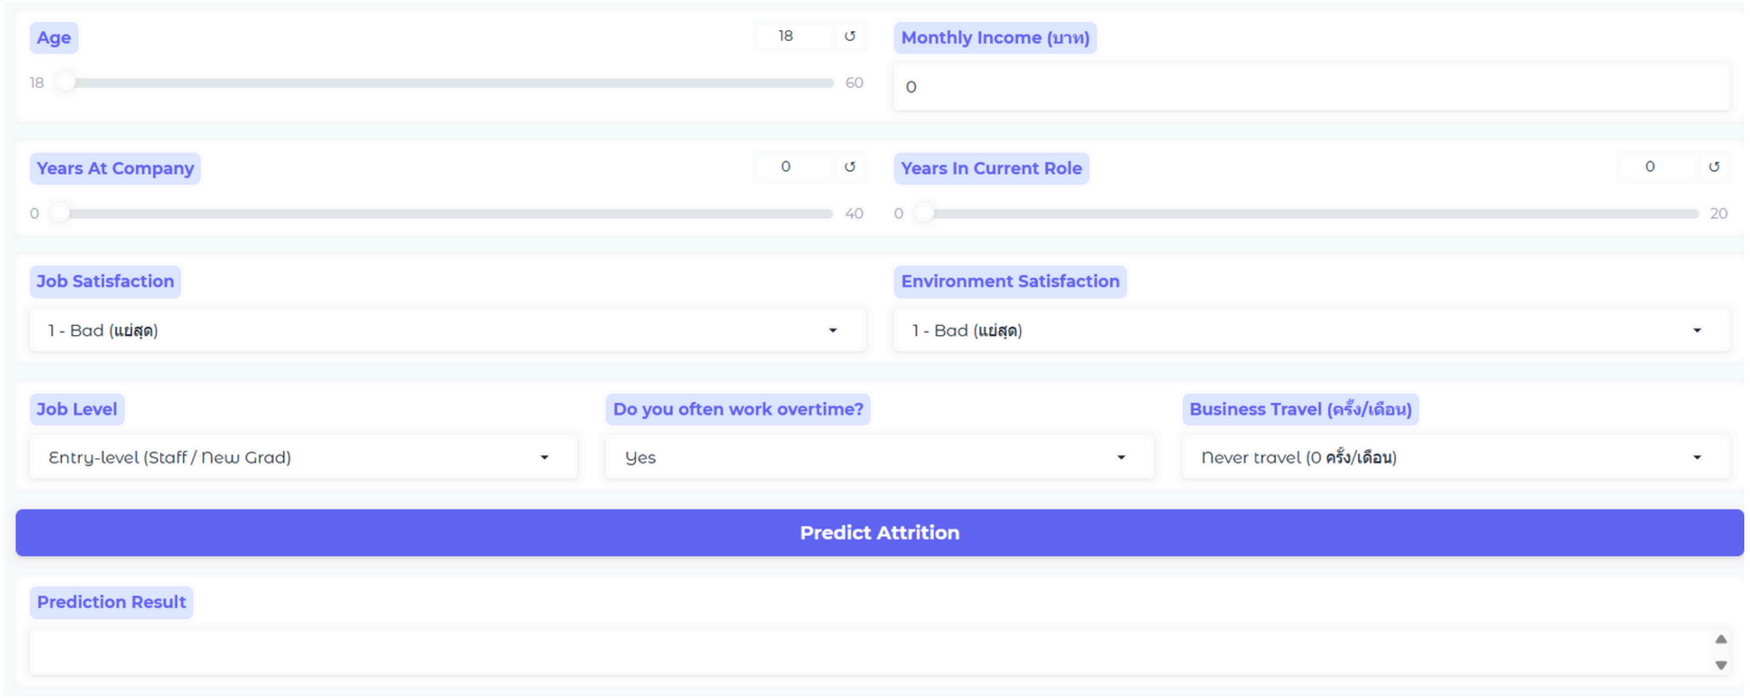
Predict Attrition

Prediction Result

วิธีใช้งานระบบ

ผู้ใช้งานต้องกรอกข้อมูล ดังนี้

- อายุ
- เงินเดือน
- จำนวนปีที่ทำงานอยู่ที่บริษัท
- จำนวนปีที่ทำงานอยู่ในตำแหน่งนี้
- ความพึงพอใจของงานที่ทำอยู่
- ความพึงพอใจของสภาพแวดล้อมการทำงาน
- ระดับตำแหน่ง
- เคยทำงานนอกเวลาไหม
- ไปทำงานนอกสถานที่บ่อยแค่ไหน



- หลังจากกรอกข้อมูลครบแล้วให้กดที่ปุ่ม Predict Attrition เพื่อส่งข้อมูลให้โมเดล
- หลังจากนั้นโมเดลจะแสดงผลการทำนายออกมาที่ช่อง Prediction Result โดยผลการทำนายมี Yes (ลาออก) และ No (ไม่ลาออก)

Links to Hugging Face Spaces

Hugging Face

https://huggingface.co/spaces/Bifern1403/Employee-Resign-Prediction/tree/main



การมีส่วนร่วมของสมาชิกในกลุ่ม

6710451402
สิรินดา ศิลปเจริญ

- ที่มาและวัตถุประสงค์ของระบบ
- ที่มาและรายละเอียดของข้อมูล
- รายละเอียดของสิ่งที่ต้องการทำนาย
- กระบวนการเตรียมข้อมูล
- กระบวนการเตรียมคุณลักษณะ

6710451208
มนัสนันท์ รัตนเกียรติขจร

- กระบวนการเลือกอัลกอริทึมที่ทดลองและใช้งาน
- กระบวนการและผลการประเมิน
- วิธีการใช้งานระบบ
- การมีส่วนร่วมของสมาชิกในกลุ่ม
- การเปิดเผยการใช้เครื่องมือปัญญาประดิษฐ์
- ลิงค์ไปยัง **Hugging Face Spaces**



การเปิดเผยการใช้เครื่องมือปัญญาประดิษฐ์

- ใช้ในการสรุป เรียบเรียง เขียนเนื้อหา ให้เข้าใจง่าย
- ใช้ในการอธิบาย และวิเคราะห์ข้อมูลของกราฟ
- ใช้ในการอธิบายว่าโค้ดส่วนนี้ใช้ทำอะไร

